


Modelo de predicción en Google Cloud con Vertex

Pablo Rosas Plaza



Módulo/Asignatura: Programación de Inteligencia Artificial

Práctica: Modelo de predicción en Google Cloud con Vertex

Alumno: Pablo Rosas Plaza

MODELO DE PREDICCIÓN DE PRECIOS BTC

Primer intento (spoiler, fallido)


Saltar esta parte, la dejo a modo de aprendizaje.

Obtenemos el dataset. El dataset tiene las siguientes columnas principales:

- **Date:** Fecha del registro (formato de texto).
- **Adj_Close:** Precio ajustado al cierre.
- **Close:** Precio de cierre.
- **High:** Precio máximo.
- **Low:** Precio mínimo.
- **Open:** Precio de apertura.
- **Volume:** Volumen de operaciones

Pero como aquí vamos con todo me he tomado el atrevimiento de añadir las siguientes columnas, que son indicadores comúnmente usados:

- **Return (%):** Cambio porcentual diario basado en el precio de cierre.
- **Moving Averages:** Promedios móviles simples (SMA) a 7 y 30 días para capturar tendencias.
- **Volatility:** Rango diario normalizado como $(High - Low) / Open$.
- **Momentum (ROC):** Tasa de cambio porcentual en los últimos 7 días.
- **RSI (Relative Strength Index):** Indicador técnico para medir la fuerza relativa del precio (comúnmente usado).



The screenshot shows the Kaggle interface for the 'Bitcoin Historical Data' dataset. The dataset is described as 'Daily BTC-USD Trading Data from 2010 to Present'. The 'About Dataset' section provides a detailed description: 'This dataset contains historical daily trading data for Bitcoin (BTC-USD) from its approximate launch date in 2010 until the present. It includes essential market data such as the opening, closing, highest, and lowest prices, as well as the adjusted closing price and trading volume. This comprehensive dataset can be used for time series analysis, forecasting, and research into Bitcoin market trends and price predictions. It serves as a valuable resource for data science projects involving cryptocurrency analysis, financial modeling, and predictive analytics.'

The 'COLUMNS' section lists the following data points:

- Date:** The specific date of the data entry.
- Open:** The opening price of Bitcoin on that date.
- High:** The highest price Bitcoin reached during the day.
- Low:** The lowest price Bitcoin fell to during the day.
- Close:** The closing price at the end of the day.
- Adj Close:** The adjusted closing price, which accounts for any stock splits and dividends.
- Volume:** The total number of Bitcoin traded on that day.

Additional metadata shown includes a Usability score of 6.47, a License of Apache 2.0, and no specified expected update frequency. The tags include 'Currencies and Foreign Exchange'.

Además le he pasado un script en python al dataset para añadir otra columna que me pedía vertex, series_id y limpiar los nulos:

```
import pandas as pd
```

```
btc_data = pd.read_csv("Bitcoin_Historical_Data_Enriched.csv")
```

```
# Eliminar filas con valores faltantes
```

```
btc_data_cleaned = btc_data.dropna()
```


```
# Añadir la columna "Series_ID" con valor constante BTC
```

```
btc_data_cleaned['Series_ID'] = 'BTC'
```


```
# Guardar el archivo limpio con Series_ID
```

```
btc_data_cleaned.to_csv("Bitcoin_Historical_DEF.csv", index=False)
```

Creemos un nuevo conjunto de datos




Creamos un nuevo bucket, como el nombre es global y no me dejaba poner el que quería (BTC bucket) en un ataque de originalidad, lo llame non_a_btc_bucket



Creamos un nuevo modelo

Elegimos como target el precio de cierre diario ajustado, el identificador series_id y el indicador temporal date, en nivel diario para indicarle que son días.



Ponemos los targets y su disponibilidad: Como son datos que queremos predecir la disponibilidad será no disponible y al ser datos numéricos los targets serán covariables.

Train new model

Método de entrenamiento

Detalles del modelo

Opciones de entrenamiento

Procesamiento y precios

COMENZAR EL ENTRENAMIENTO

CANCELAR

No se puede continuar con el siguiente paso. Resuelve todos los problemas para continuar.

Antes de continuar, usa la columna Transformación para revisar y especificar los tipos de datos de tu conjunto de datos. Si no se especifican, AutoML intentará aplicar la opción de transformación más relevante.

Estadísticas generales generadas por nov 27, 2024 6:37 p. m. [GENERAR ESTADÍSTICAS](#)

Filtro

Ingresar el nombre o el valor de la propiedad

☐	Nombre de la columna	Transformación	Tipo de función	Disponible en previsión	Porcentaje faltante (recuento)	Valores distintos
☐	Adj_Close	Numérica	Covariable	No disponible	-	3721
☐	Close	Numérica	Covariable	No disponible	-	3721
☐	Date	Marca de tiempo	Covariable	Disponible	-	3724
☐	High	Numérica	Covariable	No disponible	-	3721
☐	Low	Numérica	Covariable	No disponible	-	3722
☐	Momentum_7	Automática	Covariable	No disponible	-	-
☐	Open	Numérica	Covariable	No disponible	-	3720
☐	Return (%)	Automática	Covariable	No disponible	-	-
☐	RSI	Automática	Covariable	No disponible	-	-
☐	Series_ID					-
☐	SMA_30	Automática	Covariable	No disponible	-	-
☐	SMA_7	Automática	Covariable	No disponible	-	-
☐	Volatility	Automática	Covariable	No disponible	-	-
☐	Volume	Numérica	Covariable	No disponible	-	3724

Filas por página: 50 1 – 14 de 14

El entrenamiento incluye 13 columnas de atributos en total

Opciones Avanzadas

CONTINUAR

Configuramos el máximo de procesamiento:

Train new model

Método de entrenamiento

Detalles del modelo

Opciones de entrenamiento

Procesamiento y precios

COMENZAR EL ENTRENAMIENTO

CANCELAR

Ingresar la cantidad máxima de horas de procesamiento de nodos que quieres dedicar al entrenamiento de tu modelo.

Puedes entrenar por un mínimo de 1 node hour. Es posible que también cumplas los requisitos para entrenar con horas de procesamiento de nodos gratuitas. [Gua de precios](#)

Presupuesto *

1

Máximo de horas de procesamiento de nodos


Tiempo estimado: 1 hora

Los factores como el tamaño del conjunto de datos y la generación de métricas de evaluación pueden hacer que el entrenamiento lleve más tiempo de lo estimado


A esperar que el modelo esté listo:

Nombre	ID	Estado	Tipo de trabajo	Tipo de modelo	Duration	Última actualización	Fecha de creación	Finalizada	Etiquetas
BTC_predict_model_2024	5545474580740571136	Completo	Canalización de entrenamiento	Previsión tabular	3 h 1 min	27 nov 2024, 11:12:51 p.m.	27 nov 2024, 8:11:42 p.m.	27 nov 2024, 23:12:51	-

Por algún motivo tardó más de lo esperado, aun poniendo 1 hora en los parámetros de procesamiento máximo.



El modelo tiene un rendimiento aceptable, pero no destaca como excelente. Las métricas indican que hay margen para mejoras, especialmente en términos de la precisión relativa (MAPE) y la varianza explicada (R^2).



The screenshot shows the 'Implementar en el extremo' (Deploy to endpoint) dialog in the Vertex AI interface. The dialog is titled 'Implementar en el extremo' and includes the following sections:

- Define tu extremo**: A dropdown menu for 'Nombre del extremo' (Endpoint name) with the value `predict_btc`.
- Configuración del modelo**: A section for configuring the model deployment.
- Ubicación**: A dropdown menu for 'Región' (Region) with the value `europa-west2 (Londres)`.
- Acceso**: A section for determining access to the endpoint. The 'Estándar' (Standard) option is selected, which allows the endpoint to be accessed via a REST API.
- Opciones Avanzadas**: A section for advanced options, including a 'CONTINUAR' (Continue) button.

Creamos el modelo de predicción por lotes con un csv con tres casos que no conoce el modelo

← BTC_predict_model_2024 > Versión 1 ▾

VER CONJUNTO DE DATOS

EXPORTAR

EVALUAR

IMPLEMENTA Y PRUEBA

PREDICCIÓN POR LOTES

DETALLES DE LA VERSIÓN

LINAJE

Predicciones por lotes

En la predicción por lotes, se ingresa un grupo de solicitudes de predicción y se generan resultados para una ubicación específica. Usa esta función si no necesitas una respuesta inmediata y quieres procesar datos acumulados con una sola solicitud. [La predicción por lotes se puede usar con los modelos de AutoML](#) y con modelos de entrenamiento personalizado.

CREATE BATCH PREDICTION

Filtro

Ingresar un nombre de propiedad

Nombre	Estado	Predicciones procesadas	Última actualización ▾		
prediccion_lotes_btc	Completa		29 de noviembre de 2024		

Finalmente vemos que se han creado los ficheros en el bucket:

Google Cloud

BTC20025 ▾

Buscar (/) recursos, documentos, productos y más

Buscar

Cloud Storage

← Detalles del bucket

IR A RUTA

ACTUALIZAR

MÁS INFORMACIÓN

Descripción general

Buckets

Supervisión

Configuración

cloud-ai-platform-a3d7605a-ecac-4757-9b50-
cea9b6e31214

Ubicación

Clase de almacenamiento

Acceso público

Protección

europa-west2 (Londres)

Regional

Sujeto a LCA de objeto

Borrar de forma no definitiva

OBJETOS

CONFIGURACIÓN

PERMISOS

PROTECCIÓN

CICLO DE VIDA

OBSERVABILIDAD

INFORMES DE INVENTARIO

OPERACIONES

Navegador de carpetas

cloud-ai-platform-a3d7605a-ecac-4757-9b50-
cea9b6e31214

predict/

job-4042833611710267392/

log_monitoring/

prediction-BTC_predict_model_2024-
2024_11_29T11_12_32_36Z/

Depósitos > cloud-ai-platform-a3d7605a-ecac-4757-9b50-cea9b6e31214 > predict > prediction-BTC_predict_model_2024-2024_11_29T11_12_32_36Z

CREAR CARPETA

SUBIR ▾

TRANSFERIR LOS DATOS ▾

OTROS SERVICIOS ▾

Filtrar solo por prefijo de nombre ▾

Filtro

Filtrar objetos y carpetas

Mostrar: Solo objetos activos ▾

Nombre	Tamaño	Tipo	Fecha de creación	Clase de almacenamiento	Última modificación
prediction_errors_state-00000-of-...	141 B	text/plain	29 nov 2024 20:29:54	Regional	29 nov 2024
prediction_errors_validation-0000...	241 B	text/plain	29 nov 2024 20:18:08	Regional	29 nov 2024
prediction_errors_validation-0000...	241 B	text/plain	29 nov 2024 20:18:08	Regional	29 nov 2024
prediction_errors_validation-0000...	239 B	text/plain	29 nov 2024 20:18:08	Regional	29 nov 2024
prediction_errors_validation-0000...	241 B	text/plain	29 nov 2024 20:18:08	Regional	29 nov 2024
prediction_results-00000-of-00001...	144 B	text/plain	29 nov 2024 20:29:54	Regional	29 nov 2024

Comienza a usar Cloud Storage

Obtén información del bucket

Documento de ayuda

Obtén información sobre el tamaño y los metadatos de tus buckets de Cloud Storage.

Sube objetos

Documento de ayuda

Sube los objetos que contienen tus datos a los buckets de Cloud Storage.

Descarga objetos

Documento de ayuda

Descarga los objetos de tus buckets de Cloud Storage.

Casos de uso de Cloud Storage

Documento de ayuda

Explora casos de uso, prácticas recomendadas y soluciones del sector.

Muestras de Terraform

Documento de ayuda

Consulta ejemplos de cómo usar Terraform para crear recursos de Cloud Storage.

Guías de arquitectura para el almacenamiento

Documento de ayuda

Descubre prácticas recomendadas y arquitecturas de referencia para el almacenamiento.

Impide el acceso público


Aún teniendo un desempeño como modelo aceptable, su resultado en la predicción por lotes es tan absurdamente malo, que voy a probar a hacer un caso de modelo por clasificación discreta, en vez de numérica.

```
Date,Adj Close,Close,High,Low,Open,Volume,Return_percent,SMA_7,SMA_30,Volatility,Momentum_7,RSI,Series_ID,predicted_on_Date,predicted_Adj_Close
2024-11-27 00:00:00+00:00,,,,,,,,,,,,BTC,2024-11-27 00:00:00+00:00,4562.41259765625
2024-11-28 00:00:00+00:00,,,,,,,,,,,,BTC,2024-11-27 00:00:00+00:00,4673.45263671875
2024-11-29 00:00:00+00:00,,,,,,,,,,,,BTC,2024-11-27 00:00:00+00:00,4548.1455078125
```

MODELO DE CLASIFICACIÓN DISCRETA

Segundo intento (Road to Victory)

Trás el fracaso de mi anterior intento he decidido rehacer de nuevo la actividad pero con un modelo más similar al visto en clase.



The screenshot shows the UC Irvine Machine Learning Repository page for the 'Wine Quality' dataset. The page includes a header with navigation links (Datasets, Contribute Dataset, About Us) and a search bar. The main content area displays the dataset details, including a description, characteristics, associated tasks, and creators. The dataset is described as two datasets related to red and white vinho verde wine samples from the north of Portugal. The goal is to model wine quality based on physicochemical tests. The dataset characteristics include: Multivariate, Subject Area: Business, Associated Tasks: Classification, Regression, Feature Type: Real, # Instances: 4898, and # Features: 11. The dataset information section provides additional details, including a link to the dataset and a note about privacy and logistic issues. The creators listed are Paulo Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis. The DOI is 10.24432/C5653T and the license is Creative Commons Attribution 4.0 International (CC BY 4.0).


fuelle: <https://archive.ics.uci.edu/dataset/186/wine+quality>

Dataset que te puntúa el vino según sus características:

- **fixed acidity (acidez fija):** Representa la cantidad de ácidos orgánicos presentes en el vino que no se evaporan fácilmente, como el ácido tartárico. Esto afecta el sabor y la estabilidad del vino.
- **volatile acidity (acidez volátil):** Representa los ácidos que se evaporan fácilmente, como el ácido acético (vinagre). Un nivel alto de acidez volátil puede indicar problemas en el proceso de fermentación y puede hacer que el vino tenga un sabor desagradable.
- **citric acid (ácido cítrico):** El ácido cítrico es un tipo de ácido presente en las frutas cítricas. Aunque no está presente en grandes cantidades, su presencia puede influir en la acidez y el sabor del vino.
- **residual sugar (azúcar residual):** Es la cantidad de azúcar que permanece en el vino después de la fermentación. Este valor puede influir en el dulzor del vino. Los vinos secos tendrán poco o nada de azúcar residual, mientras que los vinos dulces tendrán más.
- **chlorides (cloruros):** Representa la cantidad de sal (cloruro de sodio) en el vino. Los niveles altos de cloruros pueden ser indicativos de una mala práctica en el proceso de vinificación o de contaminación.
- **free sulfur dioxide (dióxido de azufre libre):** El dióxido de azufre se utiliza como conservante en los vinos. El "dióxido de azufre libre" se refiere a la cantidad de dióxido de azufre que está disponible para proteger el vino de microorganismos y la oxidación. En exceso, puede afectar el sabor y aroma del vino.

- **total sulfur dioxide (dióxido de azufre total):** Representa la cantidad total de dióxido de azufre en el vino, incluyendo tanto el dióxido de azufre libre como el que está combinado con otras sustancias.
- **density (densidad):** La densidad del vino indica cuánta masa hay en un volumen dado. Esta propiedad puede estar relacionada con el contenido de alcohol y azúcar en el vino. Un vino con mayor densidad generalmente tiene más azúcar o alcohol.
- **pH (pH):** El pH mide la acidez del vino. Un pH bajo (menos de 7) indica acidez, mientras que un pH más alto indica menos acidez. El pH influye en el sabor y la estabilidad del vino.
- **sulphates (sulfatos):** Son sales derivadas del ácido sulfúrico. Los sulfatos pueden contribuir al sabor del vino y también actuar como conservantes.
- **alcohol (alcohol):** Indica el contenido de alcohol del vino. Es una de las características más importantes para definir el tipo y el estilo de un vino. Los vinos con más alcohol tienden a ser más fuertes en sabor.
- **quality (calidad):** Esta columna representa la **calificación de calidad** del vino, que es un valor numérico (del 3 al 8 en tu dataset) que refleja la calidad sensorial del vino según las pruebas de cata. Esta es la etiqueta de salida en un ejercicio de clasificación, donde el objetivo sería predecir la calidad del vino basándose en las otras características.

Creemos el conjunto de datos:



Propiedades

Fecha de creación: dic 07, 2024 5:26 p. m.

Formato del conjunto de datos: CSV

Ubicaciones de los conjuntos de datos: gs://red_wine_bucket/red-cleaned.csv

Tipo de encriptación: Administrada por Google

Resumen

Total de columnas: 12

Total de filas: -

Generando estadísticas...

Nombre de la columna	Porcentaje faltante (recuento)	Valores distintos
alcohol	-	-
chlorides	-	-
citric acid	-	-
density	-	-
fixed acidity	-	-
free sulfur dioxide	-	-
pH	-	-
quality	-	-
residual sugar	-	-
sulphates	-	-
total sulfur dioxide	-	-

Recursos relacionados

Trabajos de entrenamiento y modelos

Usa este conjunto de datos y anotaciones para entrenar un nuevo modelo de aprendizaje automático con AutoML o un código personalizado. Si seleccionas **AutoML** en **canalizaciones**, se creará una ejecución en Vertex AI Pipelines. La información de la ejecución se encontrará en la [pestaña Ejecuciones](#) en Canalizaciones.

[ENTRENAR UN MODELO NUEVO](#)

Creemos un nuevo modelo:

Train new model

- ✓ Método de entrenamiento
- 2 Detalles del modelo
- 3 Unión de un almacén de atributos (opcional)
- 4 Opciones de entrenamiento
- 5 Procesamiento y precios

COMENZAR EL ENTRENAMIENTO

CANCELAR

Dataset *
red_wine_dataset

Objetivo *
Classification

Consulta la guía de precios para obtener más detalles (y opciones de implementación disponibles) de cada método.

Ahora, puedes ejecutar el entrenamiento tabular de AutoML en Vertex AI Pipelines. Esto ofrece mayor visibilidad de cada paso del proceso de entrenamiento y un mayor nivel de personalización.

[IR A PIPELINES](#) [MÁS INFORMACIÓN](#)

Model training method

☒ AutoML
Entrena modelos de alta calidad con poco esfuerzo y experiencia en aprendizaje automático. Solo especifica por cuánto tiempo quieres entrenar el modelo. [Más información](#)

☐ Entrenamiento personalizado (avanzado)
Ejecuta tus aplicaciones de entrenamiento de TensorFlow, scikit-learn y XGBoost en la nube. Entrena con uno de los contenedores precompilados de Google Cloud o usa uno propio. [Más información](#)

[CONTINUAR](#)

Google Cloud

Vertex AI

Chat

Vision

Traducción

Voz

Galería de instrucciones

Administración de instrucc...

Ajuste

BUILD WITH GEN AI

Extensiones

DATA

Feature Store

Conjuntos de datos

MODEL DEVELOPMENT

Entrenamiento

Experimentos

Metadatos

DEPLOY AND USE

Registro de modelos

Marketplace

Train new model

- ✓ Método de entrenamiento
- 2 Detalles del modelo
- 3 Unión de un almacén de atributos (opcional)
- 4 Opciones de entrenamiento
- 5 Procesamiento y precios

COMENZAR EL ENTRENAMIENTO

CANCELAR

☒ Entrenar un modelo nuevo
Crea un nuevo grupo de modelos y asigna el modelo entrenado como versión 1

☐ Entrenar una versión nueva
Entrena el modelo como una versión de un modelo existente

Nombre *
red_wine_dataset

Descripción



Target column *
quality

☐ Export test dataset to BigQuery

OPCIONES AVANZADAS

[CONTINUAR](#)

El objetivo será clasificarlos por su nota, que está representada como la columna quality.

Métrica	Valor
PR AUC	0.673
ROC AUC	0.922
Log loss	0.868
F1 de micropromedio	0.5058366
Puntuación macro-F1	0.21170078
Precisión del promedio micro	68.4 %
Recuperación de promedio micro	40.1 %
Cantidad total de elementos	0
Elementos de entrenamiento	0
Elementos de validación	0
Elementos de prueba	0

Me sale una precisión de casi el 70 %, lo cuál es un poco bajo, una idea que se me ocurre para mejorar esto es que en vez de dejar que me clasificará la calidad del vino por su nota (habiendo 6 notas posibles), tendría que haber remplazado estas notas por tres estados posibles, es decir, las notas más bajas unificarlas en una calidad llamada baja, las dos notas intermedias unificarlas en una categoría llamada media y las dos más altas en otra categoría llamada alta, así aún perdiendo precisión real, podría ganar más precisión el modelo.

Así que probemos la predicción por lotes:

Google Cloud

Wine

buck

Vertex AI

Voz

Galería de instrucciones

Administración de instr...

Ajuste

BUILD WITH GEN AI

Extensiones

DATA

Feature Store

Conjuntos de datos

MODEL DEVELOPMENT

Entrenamiento

Experimentos

Metadatos

DEPLOY AND USE

Registro de modelos

Predicción en línea

Predicciones por lotes

Supervisión

Búsqueda de vectores

MANAGE

Ray on Vertex AI

Marketplace

Predicciones por lotes

CREAR

En la predicción por lotes, se ingresa un grupo de solicitudes de predicción y se generan resultados para una ubicación específica. Usa la predicción por lotes si no necesitas una respuesta inmediata y deseas procesar datos acumulados con una sola solicitud.

Región: europe-west2 (Londres)

Filtro: Ingresar un nombre de propiedad

Nombre	Estado	Predicciones procesadas	Modelo
No hay filas para mostrar			

Nueva predicción por lotes

Define tu predicción por lotes

Supervisión del modelo (opcional)

CREAR

CANCELAR

Nombre de predicción por lotes *

red_wine_predict

Nombre del modelo *

red_wine_model (4970852486756696064)

Versión

Versión 1

Selecciona el origen

Tabla de BigQuery

Archivo de Cloud Storage (CSV, JSONL y TFRecord)

Archivo de Cloud Storage (CSV, JSONL y TFRecord)

Tu archivo CSV debe contener los nombres de las columnas de atributos como su primera fila. [Más información sobre formatos de datos](#)

Ruta de acceso del origen *

gs://red_wine_bucket/red_wine_testing.csv

EXPLORAR

Salida de la predicción por lotes

Selecciona un formato y una ubicación de salida para los resultados de la predicción

Formato de salida

CSV

Ruta de destino *

gs://red_wine_bucket/predicts/

EXPLORAR

Opciones de explicabilidad

Sin explicabilidad

Atribución de atributos

Generar la importancia de los atributos requiere mucho más tiempo (entre 10 y 100 veces más) y solo debe hacerse cuando se realiza una predicción para un pequeño subconjunto de los datos de predicción. [Más información sobre la importancia de los atributos](#)

Google Cloud

Wine

Buscar (/) recursos, documentos, productos y más

Buscar

ACTUALIZAR

MÁS INFORMACIÓN

red_wine_predict

PROPIEDADES DE LA PREDICCIÓN POR LOTES

FUNCIONES SUPERVISADAS

VISTA PREVIA

PROPIEDADES DE LA SUPERVISIÓN

VISTA PREVIA

ID

4384561825623048192

Modelo

red_wine_model (Versión 1)

Objetivo

Tabular

Importar ubicación

gs://red_wine_bucket/red_wine_testing.csv

Cantidad total de elementos

3

Elementos previstos

3

Fecha de creación

dic 07, 2024 at 10:38p. m.

Actualizado

dic 07, 2024 at 11:00p. m.

Tiempo transcurrido

20 min 57 s

Estado

Completa

Registros

Ver registros

Ubicación de la exportación


gs://red_wine_bucket/predicts/prediction-red_wine_model-2024_12_07T13_38_04_943Z

Tipo de encriptación

Administrada por Google

Predicciones procesadas

3 predicciones correctas, 0 predicciones con errores



Como resultados de la predicción el modelo nos da sus grados de pertenencia a los posibles valores del conjunto de posibles notas, en el primer caso nos da un 64% de pertenencia la categoría 6 y un 21% de pertenencia a la categoría 7, la respuesta correcta era 7, no esta mal, aún no habiendo acertado se queda cerca.

```
es,free_sulfur_dioxide,total_sulfur_dioxi
1,0.6459155678749084,0.21932324767112732,
```

En el segundo caso no da una pertenencia del 43% a la categoría 5 de calidad del vino y del 49 % a la categoría 6, la respuesta correcta era 5, de nuevo aún no siendo acertado, se queda cerca.

```
_l_sugar,chlorides,free_sulfur_dioxide,
,0.433139443397522,0.4995260238647461,
```

En el tercer caso la respuesta era 4 y marcó un 82 % de que fuera 5, de nuevo se queda cerca, pero no termina de acertar con valores cercanos.

```
,0.8233612179756165,0.12001337110996246,0.007775146048516035,0.039268869906663895,
```

Mi conclusión final es que el modelo es bueno acertando si la calidad del vino es buena(8-9), mala(4-5) o normal(6-7), pero se lía con los valores cercanos.

La solución sería cambiar estos valores numéricos por las etiquetas de **bueno**, **normal** y **malo**, pero siento que aún aumentando la precisión del modelo en el proceso se perdería algo de información ya que no determinará con exactitud la nota del vino.

Observaciones y puntualizaciones: este dataset era de 1600 filas que es un poco más de la mitad de las permitidas (3000), si dispusiera de más filas, seguramente aumentaría la precisión del modelo, aún así estoy contento con el resultado ya que acierta el rango con

exactitud aún no tener demasiadas columnas, quizás estaría bien que google vertex te permitiera un poco más de 3000 filas para subir en los modelos de clasificación tabular.